




**TECHNISCHE
UNIVERSITÄT
DRESDEN**

Fakultät Maschinenwesen Institut für Fertigungstechnik, Professur für Fügetechnik und Montage

Experiment Design

Xiaochuan Lu



Experiment Design

Xiaochuan Lu

Geboren am: 1. November 1994 in Shandong

Studiengang: Maschinenbau

Studienrichtung: Allgemeiner Konstruktiver Maschinenbau

Matrikelnummer: 4734130

Immatrikulationsjahr: 2017

9. Juni 2020

Inhaltsverzeichnis

| | |
|--|----|
| Abbildungsverzeichnis | IV |
| Tabellenverzeichnis | V |
| Abkürzungsverzeichnis | V |
| Symbolverzeichnis | V |
| 1 DOE aus Literatur | 1 |
| 1.1 Resistance Spot Welding Optimization Based on Artificial Neural Network[1] . . . | 1 |
| 1.2 On-line Quality Estimation in Resistance Spot Welding[5] | 3 |
| 1.3 Artificial neural network-based resistance spot welding quality assessment syste[4] | 5 |
| 1.4 Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding[2] | 10 |
| 1.5 Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks[3] | 13 |
| 1.6 Performances of regression model and artificial neural network in monitoring welding quality based on power signal[6] | 17 |
| Literatur | 18 |

Abbildungsverzeichnis

| | | |
|------|--|----|
| 1.1 | The ANN structure for shear strength prediction | 2 |
| 1.2 | Estimation results | 4 |
| 1.3 | Theoretical dynamic resistance curve and nugget formation stages | 5 |
| 1.4 | RSW quality indicators | 5 |
| 1.5 | Effect of Wpar and process conditions on the RSW quality indicators | 6 |
| 1.6 | Percent contributions of Wpar in the variation of the quality indicators | 6 |
| 1.7 | Average effects of each variable in increasing or decreasing themodeling perfor- mance criteria | 8 |
| 1.8 | Percent contributions of Wpar in the variation of the quality indicators | 8 |
| 1.9 | Modeling evaluation results | 9 |
| 1.10 | Model evaluation using measured and estimated quality indicators | 9 |
| 1.11 | Sample dynamic resistance profiles for cold, expulsion, and normal welds for a CCC using MFDC | 11 |
| 1.12 | Sample dynamic resistance profile for cold, expulsion and normal welds for an AC constant heat controller | 11 |
| 1.13 | The flow chart of the algorithm | 13 |
| 1.14 | Flow chart of the coefs | 14 |
| 1.15 | The time domain of the electrode force signal | 14 |
| 1.16 | expulsion signal | 15 |
| 1.17 | The characteristic indexes of the target signal | 16 |
| 1.18 | The structure of the BP neural network | 16 |

Tabellenverzeichnis

| | | |
|-----|---------------|----|
| 1.1 | Faktor Tab. 1 | 1 |
| 1.2 | Faktor Tab. 2 | 3 |
| 1.3 | Faktor Tab. 3 | 6 |
| 1.4 | Faktor Tab. 4 | 10 |

1 DOE aus Literatur

Hier sind ein paar Methode von Experiment zum Bekommen der Experimentdaten, das RSW-Prozess optimieren und Model sowohl von Regressionsmodel aufbauen als auch von Netzwerke trainieren können.

1.1 Resistance Spot Welding Optimization Based on Artificial Neural Network[1]

Es ist notwendig, die Beziehung zwischen Parameter bei RSW-Prozess zu wissen, und Schweißqualität zu verbessern. und sich die Effizient der Prognose zu erhöhen und die Parameter zu optimieren.

Neben bekannten wichtigen Parameter wie Schweißstrom, Elektroden Kraft, Schweißzeit ist die Dicke des Werkstücks auch wichtig, was sich in einem größeren Linsewachstum bei dickeren Stücken als bei dünnen Stücken zeigt. Daher fügt diese Studie die Resistenz als Faktor hinzu.

Schweißmaschine: MFDC Rexroth Bosch

Material: Alu (6061-T6) mit 2 Blechdicke 1 mm und 2 mm (insgesamt 3 Kombinationen 1-1,2-1,2-2)

Elektrode: 6 mm Kupferelektrode

Faktor:

Tabelle 1.1 Faktor Tab. 1

| Faktor | Stufe | | |
|---------------------|-------|-----|-----|
| | I | II | III |
| Strom(kA) | 20 | 28 | 36 |
| Elektrode kraft(kN) | 2 | 4 | 6 |
| Zeit(ms) | 100 | 150 | 200 |
| Blech | 2-2 | 2-1 | 1-1 |

Autor benutzt alle Paramtereinstellung und tat 3 mal Wiederholung für jede Probe insgesamt $3^4 \times 3 = 243$

Laborprüfung:

Die fertigen Schweißverbindungen und die maximale Zugscherfestigkeit wurden geprüft und aufgezeichnet. Die Tests wurden mit dem HOUNSFIELD 50 kN bei maximaler Belastung durchgeführt.

Qualitätsparameter: Zugscherfestigkeit

ANN:

In dieser Untersuchung wurden 75% der 243 experimentellen Ergebnisse des ANN verwendet, um die Roboterschweißer zu trainieren. 25% der experimentellen Ergebnisse wurden zufällig zum Testen ausgewählt, um die vorhergesagte Scherfestigkeit mit den experimentellen Scherfestigkeitsergebnissen zu vergleichen.

- Input:
 - Strom
 - Elektrode kraft
 - Zeit
 - Blech
- Output:
 - Zugscherfestigkeit




Abbildung 1.1 The ANN structure for shear strength prediction

Durch die Berechnung einer zuverlässigen Schätzung der Scherfestigkeit können Parameter-einstellungen eine hohe Schweißqualität erzielen und reduziert sowohl die Zeit als auch den Probestest.

1.2 On-line Quality Estimation in Resistance Spot Welding[5]

Zwei Arten von Feature: die eine ist steuerbare Prozesseingangsvariablen und die andere ist Online-Signale (Elektroden Kraft, Verschiebung, dynamischer Widerstand)

Aufgrund der gekoppelten elektrisch-thermisch-mechanischen Natur weist RSW eine große Schwäche auf, d.h. es ist schwierig immer eine gute Qualität kontinuierlich zu bleiben. Die Qualität einer Schweißnaht wird im Allgemeinen durch Linsendurchmesser charakterisiert, der durch zerstörende Prüfung bestimmt wird.

In diesem Artikel wird eine Online-Methode zur Schätzung der Linsendurchmesser vorgestellt, die auf neuronalen Netzen und einer systematischen Merkmalsauswahl basiert. Es hat sich unter einer Vielzahl von Schweißbedingungen als erfolgreich erwiesen.

Das Linsewachstum ist abhängig von Elektroden Kraft und Verschiebung und dynamischer Widerstand. Von jeder Kurve (Elektroden Kraft, Verschiebung, dynamischer Widerstand) können 24 Punkte gekriegt werden und wieder addieren 3 Variabel, Root Mean Square Strom, Vorkraft und Schweißzeit insgesamt 27 Feature.

In den 27 Feature können sie untereinander korreliert sein und daher können unnötige Informationen existieren. Um die Korrelation zu beseitigen, wurde eine PCA (Principal component analysis) verwendet, d.h die Dimension kann reduziert basierend auf Varianzverhältnis werden.

Schweißparameter: 75 KVA Einphasen-Wechselstrom-Sockel Schweißer

Material: 0,8 mm AKDQ Stahl

Elektrode: 6,4 mm CuZr-Kegelstumpfelektroden

Qualitätsparameter: Linsendurchmesser

Faktor:

Tabelle 1.2 Faktor Tab. 2

| Faktor | Bedingungen |
|------------------------|-------------|
| Elektrode Kraft(kN) | 3,0...4,0 |
| Strom(kA) | 6,9...13,4 |
| Zeit(Zyklen) | 3...36 |
| Kontaktdurchmesser(mm) | 6,4...7,2 |

Insgesamt 170 Proben werden unter verschiedenen Bedingungen gesammelt, davon 120 Randomsamples zum Training und 50 Samples zur Validierung. Nach PAC (principal component analysis) wird Die Input Dimension auf 7 reduziert.

- Input:
 - 7 D
- Hidden Layer1:
 - 14
- Hidden Layer2:
 - 5
- Output:

- Linsendurchmesser

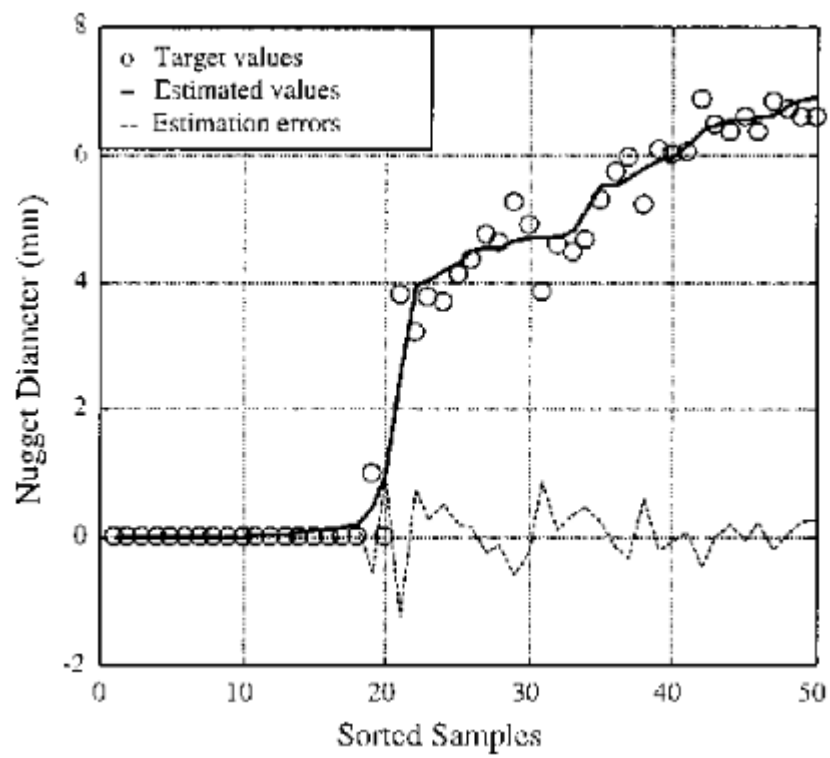


Abbildung 1.2 Estimation results

1.3 Artificial neural network-based resistance spot welding quality assessment system[4]

Neben Schweißparameter wie Schweißspannung, Strom, Zeit und Kraft gehören Elektrodenverschiebung, Elektrodenkraft, Temperaturschwankung, Schallemission, Ultraschallprüfung und dynamischer Widerstand ebenfalls zu wichtigen Qualitätsindikatoren in RSW. In diesen Indikatoren existieren dynamischer Widerstand und Qualitätsindikatoren deutlich Beziehung. [Abbildung 1.3](#) zeigt eine starke Korrelation zwischen den verschiedenen Entwicklungsphasen des RSW und der Form der DR Kurve. Deswegen möchte der Autor die Feature durch Kombination zwischen Schweißparameter und DR Kurve in ANN benutzen




Abbildung 1.3 Theoretical dynamic resistance curve and nugget formation stages

Schweißmaschine: tragbares Mittelfrequenz-DC-Schweißgerät

Material: verzinkte kohlenstoffarme Stahlbleche

Elektrode: wassergekühlte 45°-Kegelstumpf-RWMA-C2-Elektrode (CuCrZr) mit 8 mm Flächen-durchmesser. Um Verschleiß und Zinkablagerungen zu minimieren, sollten die Elektroden durch Auswahl der geeigneten Elektrodenform und durch Verwendung von Wasserkühlung und Steuerung der Schweißgeschwindigkeit so kühl wie möglich gehalten werden.

Qualitätsparameter: Elektrodeneindringtiefe e_u , Linsendurchmesser d_n , Linseneindringtiefe p . Das resultierende Nugget wurde unter Verwendung eines metallografischen Standardverfahrens hergestellt und gemessen.





Abbildung 1.4 RSW quality indicators

Faktor:

Tabelle 1.3 Faktor Tab. 3

| Faktor | Training sets | Validation sets |
|-------------------------|---------------|-----------------|
| ST: Blechdicke(mm) | 0,95...1,85 | 0,95...1,85 |
| WC: Schweißstrom(A) | 6,25...9,50 | 6,25...9,50 |
| EF: Elektrodenkraft (N) | 184...400 | 184...400 |
| WT: Schweißzeit (s) | 300...500 | 300...500 |

wenn alle Parametereinstellung benutzt und Wiederholung der Versuche zur Reduzierung des experimentellen Fehlers gemacht wird, kann max. insgesamt $3^4 \times 2 = 162$ Versuche gebraucht werden. Offensichtlich wird so viel Versuche durchzuführen zu viel Zeit in Anspruch nehmen. Die Anzahl der Versuche wurde mit zwei OAs (L27 und L9) auf 36 reduziert.

Experiment Ergebnisse Analyse:




Abbildung 1.5 Effect of Wpar and process conditions on the RSW quality indicators

| Quality indicators | Welding parameters | | | | Interactions | | Error |
|--------------------|--------------------|-------|------|-------|--------------|-------|-------|
| | ST | WC | EF | WT | WC -WT | EF-WT | |
| I_{dep} | 5.90 | 73.51 | — | 2.89 | — | 4.41 | 13.29 |
| N_{dia} | 3.17 | 75.02 | 3.18 | 3.99 | — | 2.32 | 12.32 |
| N_{pen} | 53.08 | 3.54 | 8.71 | 14.59 | 1.96 | — | 18.12 |

Abbildung 1.6 Percent contributions of Wpar in the variation of the quality indicators

Diese Ergebnisse zeigen, dass der Fehlerbeitrag relativ hoch ist. Dies bedeutet, dass wichtige Faktoren, die die RSW-Qualität beeinflussen, nicht in die Experimente einbezogen wurden. Dementsprechend kann davon ausgegangen werden, dass die Qualitätsindikatoren nicht nur mit ST, WC und WT gesteuert werden können.

ANN:

Neue Qualitätsindikatoren ST WC EF WT und DR (mit mindestens 6 gleichmäßig verteilten Punkten).

- Input:
 - n
- Hidden Layer1:
 - $2n+1$
- Output:
 - Elektrodeneindringtiefe e_u
 - Linsendurchmesser d_n
 - Linseneindringtiefe p

Für Feature Selection könnte OA L8 verwendet werden.




Abbildung 1.7 Average effects of each variable in increasing or decreasing the modeling performance criteria

| Quality indicators | Welding parameters | | | | Interactions | | Error |
|--------------------|--------------------|-------|------|-------|--------------|---------|-------|
| | ST | WC | EF | WT | WC - WT | EF - WT | |
| I_{dep} | 5.90 | 73.51 | – | 2.89 | – | 4.41 | 13.29 |
| N_{dia} | 3.17 | 75.02 | 3.18 | 3.99 | – | 2.32 | 12.32 |
| N_{pen} | 53.08 | 3.54 | 8.71 | 14.59 | 1.96 | – | 18.12 |

Abbildung 1.8 Percent contributions of Wpar in the variation of the quality indicators

| Model identification | | WP _m | DR _m | QO _m | |
|----------------------|------------------------|-------------------|-----------------|-----------------|--------|
| Modeling variables | ST | 1 | 2 | 2 | |
| | WC | 1 | 2 | 1 | |
| | EF | 1 | 2 | 2 | |
| | WT | 1 | 2 | 2 | |
| | DR | 2 | 1 | 1 | |
| Decision criteria | Training RMSE values | I _{dep} | 0.0080 | 0.0268 | 0.0052 |
| | | N _{dia} | 0.1061 | 0.3767 | 0.1091 |
| | | N _{pen} | 1.2445 | 4.9358 | 0.9146 |
| | | RMSE _t | 1.3586 | 5.3393 | 1.0288 |
| | Validation RMSE values | I _{dep} | 0.0245 | 0.0296 | 0.0184 |
| | | N _{dia} | 0.3438 | 0.3408 | 0.5180 |
| | | N _{pen} | 2.5737 | 3.7138 | 1.4585 |
| | | RMSE _v | 2.9420 | 4.0842 | 1.9949 |
| | RMSE _{tot} | | 4.3005 | 9.4235 | 3.9641 |
| | Training MRE values | I _{dep} | 0.0424 | 0.1250 | 0.0322 |
| | | N _{dia} | 0.0176 | 0.0637 | 0.0175 |
| | | N _{pen} | 0.0192 | 0.0705 | 0.0106 |
| | | MRE _t | 0.0793 | 0.2592 | 0.0603 |
| | Validation MRE values | I _{dep} | 0.0784 | 0.0939 | 0.0650 |
| | | N _{dia} | 0.0391 | 0.0515 | 0.0519 |
| | | N _{pen} | 0.0266 | 0.0512 | 0.0180 |
| | | MRE _v | 0.1441 | 0.1966 | 0.1350 |
| | MRE _{tot} | | 0.2233 | 0.4558 | 0.1953 |

Abbildung 1.9 Modeling evaluation results

Ein quasi optimales Modell entwickelt, das **Schweißparameter** und typische Eigenschaften des dynamischen Widerstands kombiniert.




Abbildung 1.10 Model evaluation using measured and estimated quality indicators

1.4 Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding[2]

In diesem Artikel wird ein algorithmisches Framework vorgeschlagen, das auf einem neuronalen Netzwerk mit linear vector quantization (LVQ) basiert und die Klassifizierung von Linsequalität basierend auf einer kleinen Anzahl dynamischer Widerstandsmuster für Kalt-, Normal- und Spritzer schätzt, die während des Stabilisierungsprozesses gesammelt werden.

Die Klassifizierung der Linse-Qualität mithilfe eines LVQ-Netzwerks wurde auf zwei Arten von Controllern getestet: MFDC mit konst. Stromregler and AC mit konst. Wärmeregler.

Um die Dimension des Eingabedatenvektors zu verringern, werden verschiedene Punkt aus dem dynamischen Widerstandsprofil extrahiert und unter Verwendung der Leistung der Testkriterien verglichen.

Schweißmaschine: MFDC mit Konstantstromregler, AC mit konstantem Wärmeregler

Material: 2,00 mm Feuerverzinkter HSLA-Stahl mit 0,85 mm Galvanisch verzinkter HSLA-Stahl

Elektrode: HWPAL25 mit einem Flächendurchmesser von 6,4 mm

Faktor:

Tabelle 1.4 Faktor Tab. 4

| Faktor | MFDC(Konstantstromregler) | AC(Konstantwärmeregler) |
|---------------------|--------------------------------------|-------------------------|
| Schweißstrom(kA) | 11,5 mit 1 A Anstieg pro Schweißung. | 11,3 |
| Elektrodenkraft(lb) | 680 | 680 |
| Schweißzeit | 233 ms | 16 Zyklen |

Elf Batches mit jeweils 300 Schweißnähten (insgesamt 3,300 Schweißnähte ohne Ankerschweißpunkte) wurden mit 10 Elektroden durchgeführt, die nach jeden Batches bearbeitet wurden. Im Fall des MFDC Tests wurde jedes Batche 50 Samples ausgewählt. Deswegen wurde insgesamt 550 Linsedurchmesser gemessen. Davon haben 411 mit guter Qualität, 22 mit schlecht Qualität und 117 mit Spritzer.

Im Fall des AC Tests wurde 720 Samples ausgewählt. Davon 509 mit guter Qualität und 211 mit Spritzer

In allen Tests basiert die Klassifizierung der Linse-Qualität auf dem Widerstandsprofil

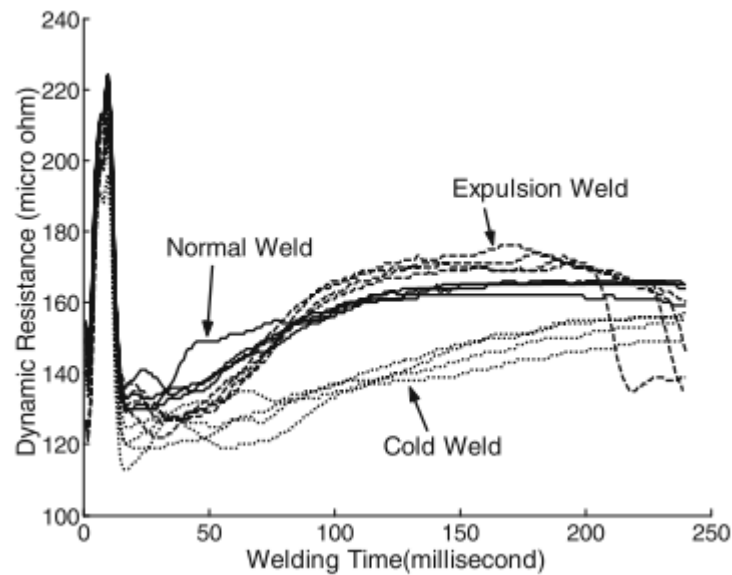


Abbildung 1.11 Sample dynamic resistance profiles for cold, expulsion, and normal welds for a CCC using MFDC

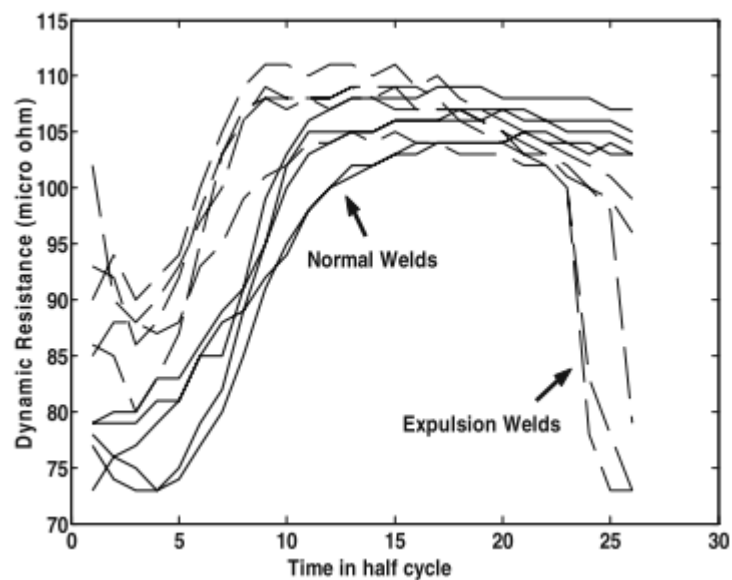


Abbildung 1.12 Sample dynamic resistance profile for cold, expulsion and normal welds for an AC constant heat controller

Das LVQ-Modell wurde an 3, 6 und 5 Samples des sekundären Widerstandsvektors für Kalt-, Normal- bzw. Spritzer-Schweiß trainiert.

LVQ:

- MFDC Konstantstromregler
 - Input:
 - * 167 Dimension gleich der Anzahl der Millisekunden-Samples in einem Schweißen ohne die ersten 67 ms
 - Hidden Layer:
 - * 12
 - Output:

- * schlecht
- * gut
- * Spritzer
- AC Konstantwärmeregler
 - Input:
 - * 24 Dimension gleich der Anzahl der Halbzyklen in einem Schweißen nach der Vorheiz- und Abkühlphase
 - Hidden Layer:
 - * 12
 - Output:
 - * schlecht
 - * gut
 - * Spritzer

Um die Dimension des Eingangs zu verringern, wurde der tatsächliche Widerstandsvektor durch eine Reihe repräsentativer Merkmale ersetzt.

- R_{max}
- R_{min}
- \bar{R}
- SD des Eingangswiderstands
- ΔR
- RMS
- Steigungswert der ersten Region ($S1$) des Eingangswiderstands
- Steigungswert der zweiten Region ($S2$) des Eingangswiderstands
- Steigungswert der dritten Region ($S3$) des Eingangswiderstands
- Steigungswert der vierten Region ($S4$) des Eingangswiderstands
- Binned RMS des Eingangswiderstands; Der Eingangswiderstand ist in fünf Bins unterteilt und die RMS werden für jeden Bin berechnet

Die Ergebnisse aus der Anwendung des LVQ neuronalen Netzes trainiert, indem sie die sehr begrenzte Daten während des Stabilisierungsprozesses gesammelt verwenden, sind sehr vielversprechend und werden im Detail berichtet.

Darüber hinaus berichten wir vielversprechende Ergebnisse sehr, wenn ein reduzierter Feature für die Einstufung verwendet wird, anstatt das gesamte dynamische Widerstandsprofil.

1.5 Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks[3]

Die Spritzeridentifikation hat für die Bewertung und Kontrolle der Schweißqualität beim RSW größte Bedeutung. Um die Identifikationsgenauigkeit zu verbessern, wurden neuartige neuronale Netze für Wavelet decomposition und Back Propagation (BP) mit der Peak-Peak-Amplitude und dem Kurtosis-Index vorgeschlagen um den Spritzer von Elektrodenkraft-Erfassungssignalen zu identifizieren.

Das Elektrodenkraftsignal ist ein typisches instationäres Signal, dessen verteilte Parameter sich mit der Zeit ändern. Daher konnte weder die Zeitbereichsanalyse noch die Frequenzbereichsanalyse das Signal genau ausdrücken. Die Wavelet-decomposition ist eine Art stabiles und schnelles Zeit-Frequenz-Signalanalyseverfahren.





Figure 5. The flow chart of the algorithm.

Abbildung 1.13 The flow chart of the algorithm

Signal Processing: Der Prozess führte eine mehrstufige eindimensionale Wavelet-Analyse unter Verwendung spezifischer Wavelet-Zerlegungsfilter durch, einschließlich des Tiefpassfilters und des Hochpassfilters.



$\downarrow 2$: Downsampling by the factor of 2

Abbildung 1.14 Flow chart of the coefs

Schließlich wurde die Energie jedes Detailsignals $Q_x(t)$ berechnet und das höchste als Zielsignal ausgewählt. Die Peak-Peak-Amplitude und dem Kurtosis-Index des Zielsignals wurden als Eingabeparameter des BP Neur berechnet. Folgende sind 3 typische Kraftsignale, daher könnte die Anschlag-Feature als Hauptspritzermerkmal bei der Unterscheidung des Spritzer verwendet werden.




Abbildung 1.15 The time domain of the electrode force signal

Durch Wavelet decomposition wurde die Signals auf jeden Layer bekommen:




Abbildung 1.16 explosion signal

In dieser Arbeit wurde der Energieverteilung des Signals in jeder Schicht berechnet und das höchste als Zielsignal ausgewählt.

| Data | Peak-to-Peak Amplitude | Kurtosis Index | Layer of the Maximum Energy |
|------|------------------------|----------------|-----------------------------|
| 1 | 6962.3 | 115.78 | Layer 6 |
| 2 | 4318.7 | 83.79 | Layer 6 |
| 3 | 4408.2 | 84.00 | Layer 6 |
| 4 | 112.3 | 8.06 | Layer 7 |
| 5 | 408.86 | 92.93 | Layer 7 |
| 6 | 198.21 | 10.75 | Layer 7 |
| 7 | 95.61 | 7.88 | Layer 7 |
| 8 | 1402.1 | 27.66 | Layer 7 |
| 9 | 373.08 | 8.94 | Layer 7 |
| 10 | 2674.9 | 93.31 | Layer 7 |
| 11 | 5047.7 | 180.80 | Layer 6 |
| 12 | 4560.3 | 141.76 | Layer 6 |
| 13 | 4526.8 | 134.79 | Layer 6 |
| 14 | 128.10 | 15.58 | Layer 7 |
| 15 | 841.12 | 82.14 | Layer 7 |
| 16 | 564.10 | 46.86 | Layer 7 |
| 17 | 153.99 | 14.55 | Layer 7 |
| 18 | 228.79 | 14.58 | Layer 7 |
| 19 | 2406.7 | 83.54 | Layer 6 |
| 20 | 5087.6 | 144.21 | Layer 6 |

Abbildung 1.17 The characteristic indexes of the target signal




Abbildung 1.18 The structure of the BP neural network

- Input:
 - Peak-Peak-Amplitude
 - Kurtosis-Index
- Hidden Layer:
 - 5
- Output:
 - 1 oder -1 (1: Spritzer, -1: ohne Spritzer)

1.6 Performances of regression model and artificial neural network in monitoring welding quality based on power signal[6]

In dieser Studie wurde eine Untersuchung durchgeführt, um die Leistung des Regressionsmodells und des künstlichen neuronalen Netzwerks bei der Vorhersage des Linsendurchmesser von RSW durch Überwachung der dynamischen Leistungssignatur zu vergleichen.

Ein Echtzeit-Erfassungssystem vorgestellt, nach dem der Schweißstrom und die Schweißspannung im Sekundärkreis erhalten wurden. Das Leistungssignal wurde erfasst und analysiert, um die Schweißqualitäten zu charakterisieren. Die Schweißqualitäten können als schlechte , gute Spritzer-Schweißnähte klassifiziert werden. Die Feature mit physikalischen Bedeutungen wurden aus dem Leistungssignal extrahiert, um die Variationen im Signal zu identifizieren, und sie wurden dann als Eingaben des künstlichen neuronalen Netzwerks und des Regressionsmodells benutzt. Die Vorhersagegenauigkeit der Modelle wurde ebenfalls diskutiert.

Literatur

- [1] Thongchai Arunchai u. a. „Resistance Spot Welding Optimization Based on Artificial Neural Network“. In: *International Journal of Manufacturing Engineering* 2014 (2014), S. 1–6. ISSN: 2356-7023. DOI: [10.1155/2014/154784](https://doi.org/10.1155/2014/154784).
- [2] Mahmoud El-Banna, Dimitar Filev und Ratna Babu Chinnam. „Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding“. In: *The International Journal of Advanced Manufacturing Technology* 36.3-4 (2008), S. 237–248. ISSN: 0268-3768. DOI: [10.1007/s00170-006-0835-5](https://doi.org/10.1007/s00170-006-0835-5).
- [3] Shujun Chen u. a. „Expulsion Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks“. In: *Applied Sciences* 9.19 (2019), S. 4028. DOI: [10.3390/app9194028](https://doi.org/10.3390/app9194028).
- [4] A. El Ouafi, R. Bélanger und J. F. Méthot. „Artificial neural network-based resistance spot welding quality assessment system“. In: *Revue de Métallurgie* 108.6 (2011), S. 343–355. ISSN: 0035-1563. DOI: [10.1051/meta1/2011066](https://doi.org/10.1051/meta1/2011066).
- [5] Wei Li, S. Jack Hu und Jun Ni. „On-line Quality Estimation in Resistance Spot Welding“. In: *Journal of Manufacturing Science and Engineering* 122.3 (2000), S. 511–512. ISSN: 1087-1357. DOI: [10.1115/1.1286814](https://doi.org/10.1115/1.1286814).
- [6] Dawei Zhao u. a. „Performances of regression model and artificial neural network in monitoring welding quality based on power signal“. In: *Journal of Materials Research and Technology* 9.2 (2020), S. 1231–1240. ISSN: 22387854. DOI: [10.1016/j.jmrt.2019.11.050](https://doi.org/10.1016/j.jmrt.2019.11.050).