



**TECHNISCHE  
UNIVERSITÄT  
DRESDEN**


---

Fakultät Maschinenwesen Institut für Fertigungstechnik, Professur für Fügetechnik und Montage

---

# Experiment Design

Xiaochuan Lu



# Experiment Design

Xiaochuan Lu

Geboren am: 1. November 1994 in Shandong

Studiengang: Maschinenbau

Studienrichtung: Allgemeiner Konstruktiver Maschinenbau

Matrikelnummer: 4734130

Immatrikulationsjahr: 2017

11. Juni 2020

# Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	V
Symbolverzeichnis	V
1 DOE aus Literatur	1
1.1 Resistance Spot Welding Optimization Based on Artificial Neural Network[1]	1
1.2 On-line Quality Estimation in Resistance Spot Welding[5]	3
1.3 Artificial neural network-based resistance spot welding quality assessment syste[4]	5
1.4 Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding[2]	10
1.5 Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks[3]	13
1.6 Performances of regression model and artificial neural network in monitoring welding quality based on power signal[8]	17
1.7 Optimization of resistance spot welding process using taguchi method and a neural network[6]	20
1.8 Quality evaluation by classification of electrode force patterns in the resistance spot welding process using neural networks[7]	23
Literatur	26

# Abbildungsverzeichnis

1.1	The ANN structure for shear strength prediction . . . . .	2
1.2	Estimation results . . . . .	4
1.3	Theoretical dynamic resistance curve and nugget formation stages . . . . .	5
1.4	RSW quality indicators . . . . .	5
1.5	Effect of Wpar and process conditions on the RSW quality indicators . . . . .	6
1.6	Percent contributions of Wpar in the variation of the quality indicators . . . . .	6
1.7	Average effects of each variable in increasing or decreasing themodeling perfor- mance criteria . . . . .	8
1.8	Percent contributions of Wpar in the variation of the quality indicators . . . . .	8
1.9	Modeling evaluation results . . . . .	9
1.10	Model evaluation using measured and estimated quality indicators . . . . .	9
1.11	Sample dynamic resistance profiles for cold, expulsion, and normal welds for a CCC using MFDC . . . . .	11
1.12	Sample dynamic resistance profile for cold, expulsion and normal welds for an AC constant heat controller . . . . .	11
1.13	The flow chart of the algorithm . . . . .	13
1.14	Flow chart of the coefs . . . . .	14
1.15	The time domain of the electrode force signal . . . . .	14
1.16	expulsion signal . . . . .	15
1.17	The characteristic indexes of the target signal . . . . .	16
1.18	The structure of the BP neural network . . . . .	16
1.19	Welding powers signals for various welding qualities . . . . .	17
1.20	Measurement system used in the welding process . . . . .	17
1.21	Three types of welding joints with different failure: (a) Schlecht mit IF (b) Spritzer mit IF (c) Gut mit PF . . . . .	18
1.22	Typical mechanical properties of three types of welding joints . . . . .	18
1.23	SNR graph for the tensile shear strength . . . . .	20
1.24	The best welding parameters selected by ANN . . . . .	21
1.25	Surface conditions of specimens for validating the proposed approach . . . . .	22
1.26	Electrode force patterns for various welding forces . . . . .	23
1.27	Electrode force patterns for various welding currents . . . . .	24
1.28	Welding qualities of the standard welding quality classes . . . . .	24
1.29	Select slope feature from force pattern and used in ANN input . . . . .	25
1.30	Block diagram of the training and estimation procedures for electrode force slope patterns using the proposed BP neural network . . . . .	25

# Tabellenverzeichnis

1.1	Faktor Tab. 1	1
1.2	Faktor Tab. 2	3
1.3	Faktor Tab. 3	6
1.4	Faktor Tab. 4	10
1.5	Faktor Tab. 5	18
1.6	Faktor Tab. 6	20
1.7	Faktor Tab. 7	23

# 1 DOE aus Literatur

Hier sind ein paar Methode von Experiment zum Bekommen der Experimentdaten, das RSW-Prozess optimieren und Model sowohl von Regressionsmodel aufbauen als auch von Netzwerke trainieren können.

## 1.1 Resistance Spot Welding Optimization Based on Artificial Neural Network[1]

Es ist notwendig, die Beziehung zwischen Parameter bei RSW-Prozess zu wissen, und Schweißqualität zu verbessern. und sich die Effizient der Prognose zu erhöhen und die Parameter zu optimieren.

Neben bekannten wichtigen Parameter wie Schweißstrom, Elektroden Kraft, Schweißzeit ist die Dicke des Werkstücks auch wichtig, was sich in einem größeren Linsewachstum bei dickeren Stücken als bei dünnen Stücken zeigt. Daher fügt diese Studie die Resistenz als Faktor hinzu.

**Schweißmaschine:** MFDC Rexroth Bosch

**Material:** Alu (6061-T6) mit 2 Blechdicke 1 mm und 2 mm (insgesamt 3 Kombinationen 1-1,2-1,2-2)

**Elektrode:** 6 mm Kupferelektrode

**Faktor:**

Tabelle 1.1 Faktor Tab. 1

Faktor	Stufe		
	I	II	III
Strom(kA)	20	28	36
Elektrode kraft(kN)	2	4	6
Zeit(ms)	100	150	200
Blech	2-2	2-1	1-1

Autor benutzt alle Paramtereinstellung und tat 3 mal Wiederholung für jede Probe insgesamt  $3^4 \times 3 = 243$

### Laborprüfung:

Die fertigen Schweißverbindungen und die maximale Zugscherfestigkeit wurden geprüft und aufgezeichnet. Die Tests wurden mit dem HOUNSFIELD 50 kN bei maximaler Belastung durchgeführt.

### Qualitätsparameter: Zugscherfestigkeit

#### ANN:

In dieser Untersuchung wurden 75% der 243 experimentellen Ergebnisse des ANN verwendet, um die Roboterschweißer zu trainieren. 25% der experimentellen Ergebnisse wurden zufällig zum Testen ausgewählt, um die vorhergesagte Scherfestigkeit mit den experimentellen Scherfestigkeitsergebnissen zu vergleichen.

- Input:
  - Strom
  - Elektrode kraft
  - Zeit
  - Blech
- Output:
  - Zugscherfestigkeit




Abbildung 1.1 The ANN structure for shear strength prediction

Durch die Berechnung einer zuverlässigen Schätzung der Scherfestigkeit können Parameter-einstellungen eine hohe Schweißqualität erzielen und reduziert sowohl die Zeit als auch den Probestest.

## 1.2 On-line Quality Estimation in Resistance Spot Welding[5]

Zwei Arten von Feature: die eine ist steuerbare Prozesseingangsvariablen und die andere ist Online-Signale (Elektroden Kraft, Verschiebung, dynamischer Widerstand)

Aufgrund der gekoppelten elektrisch-thermisch-mechanischen Natur weist RSW eine große Schwäche auf, d.h. es ist schwierig immer eine gute Qualität kontinuierlich zu bleiben. Die Qualität einer Schweißnaht wird im Allgemeinen durch Linsendurchmesser charakterisiert, der durch zerstörende Prüfung bestimmt wird.

In diesem Artikel wird eine Online-Methode zur Schätzung der Linsendurchmesser vorgestellt, die auf neuronalen Netzen und einer systematischen Merkmalsauswahl basiert. Es hat sich unter einer Vielzahl von Schweißbedingungen als erfolgreich erwiesen.

Das Linsewachstum ist abhängig von Elektroden Kraft und Verschiebung und dynamischer Widerstand. Von jeder Kurve (Elektroden Kraft, Verschiebung, dynamischer Widerstand) können 24 Punkte gekriegt werden und wieder addieren 3 Variabel, Root Mean Square Strom, Vorkraft und Schweißzeit insgesamt 27 Feature.

In den 27 Feature können sie untereinander korreliert sein und daher können unnötige Informationen existieren. Um die Korrelation zu beseitigen, wurde eine PCA (Principal component analysis) verwendet, d.h. die Dimension kann reduziert basierend auf Varianzverhältnis werden.

**Schweißparameter:** 75 KVA Einphasen-Wechselstrom-Sockel Schweißer

**Material:** 0,8 mm AKDQ Stahl

**Elektrode:** 6,4 mm CuZr-Kegelstumpfelektroden

**Qualitätsparameter:** Linsendurchmesser

**Faktor:**

Tabelle 1.2 Faktor Tab. 2

Faktor	Bedingungen
Elektrode Kraft(kN)	3,0...4,0
Strom(kA)	6,9...13,4
Zeit(Zyklen)	3...36
Kontaktdurchmesser(mm)	6,4...7,2

Insgesamt 170 Proben werden unter verschiedenen Bedingungen gesammelt, davon 120 Randomsamples zum Training und 50 Samples zur Validierung. Nach PAC (principal component analysis) wird Die Input Dimension auf 7 reduziert.

- Input:
  - 7 D
- Hidden Layer1:
  - 14
- Hidden Layer2:
  - 5
- Output:



- Linsendurchmesser




Abbildung 1.2 Estimation results

### 1.3 Artificial neural network-based resistance spot welding quality assessment system[4]

Neben Schweißparameter wie Schweißspannung, Strom, Zeit und Kraft gehören Elektrodenverschiebung, Elektrodenkraft, Temperaturschwankung, Schallemission, Ultraschallprüfung und dynamischer Widerstand ebenfalls zu wichtigen Qualitätsindikatoren in RSW. In diesen Indikatoren existieren dynamischer Widerstand und Qualitätsindikatoren deutlich Beziehung. [Abbildung 1.3](#) zeigt eine starke Korrelation zwischen den verschiedenen Entwicklungsphasen des RSW und der Form der DR Kurve. Deswegen möchte der Autor die Feature durch Kombination zwischen Schweißparameter und DR Kurve in ANN benutzen




Abbildung 1.3 Theoretical dynamic resistance curve and nugget formation stages

**Schweißmaschine:** tragbares Mittelfrequenz-DC-Schweißgerät

**Material:** verzinkte kohlenstoffarme Stahlbleche

**Elektrode:** wassergekühlte 45°-Kegelstumpf-RWMA-C2-Elektrode (CuCrZr) mit 8 mm Flächen-durchmesser. Um Verschleiß und Zinkablagerungen zu minimieren, sollten die Elektroden durch Auswahl der geeigneten Elektrodenform und durch Verwendung von Wasserkühlung und Steuerung der Schweißgeschwindigkeit so kühl wie möglich gehalten werden.

**Qualitätsparameter:** Elektrodeneindringtiefe  $e_u$ , Linsendurchmesser  $d_n$ , Linseneindringtiefe  $p$ . Das resultierende Nugget wurde unter Verwendung eines metallografischen Standardverfahrens hergestellt und gemessen.





Abbildung 1.4 RSW quality indicators

Faktor:

Tabelle 1.3 Faktor Tab. 3

Faktor	Training sets	Validation sets
ST: Blechdicke(mm)	0,95...1,85	0,95...1,85
WC: Schweißstrom(A)	6,25...9,50	6,25...9,50
EF: Elektrodenkraft (N)	184...400	184...400
WT: Schweißzeit (s)	300...500	300...500

wenn alle Parametereinstellung benutzt und Wiederholung der Versuche zur Reduzierung des experimentellen Fehlers gemacht wird, kann max. insgesamt  $3^4 \times 2 = 162$  Versuche gebraucht werden. Offensichtlich wird so viel Versuche durchzuführen zu viel Zeit in Anspruch nehmen. Die Anzahl der Versuche wurde mit zwei OAs (L27 und L9) auf 36 reduziert.

Experiment Ergebnisse Analyse:




Abbildung 1.5 Effect of Wpar and process conditions on the RSW quality indicators

Quality indicators	Welding parameters				Interactions		Error
	ST	WC	EF	WT	WC -WT	EF-WT	
$I_{dep}$	5.90	73.51	—	2.89	—	4.41	13.29
$N_{dia}$	3.17	75.02	3.18	3.99	—	2.32	12.32
$N_{pen}$	53.08	3.54	8.71	14.59	1.96	—	18.12

Abbildung 1.6 Percent contributions of Wpar in the variation of the quality indicators

Diese Ergebnisse zeigen, dass der Fehlerbeitrag relativ hoch ist. Dies bedeutet, dass wichtige Faktoren, die die RSW-Qualität beeinflussen, nicht in die Experimente einbezogen wurden. Dementsprechend kann davon ausgegangen werden, dass die Qualitätsindikatoren nicht nur mit ST, WC und WT gesteuert werden können.

**ANN:**

Neue Qualitätsindikatoren ST WC EF WT und DR (mit mindestens 6 gleichmäßig verteilten Punkten).

- Input:
  - $n$
- Hidden Layer1:
  - $2n+1$
- Output:
  - Elektrodeneindringtiefe  $e_u$
  - Linsendurchmesser  $d_n$
  - Linseneindringtiefe  $p$

Für Feature Selection könnte OA L8 verwendet werden.




Abbildung 1.7 Average effects of each variable in increasing or decreasing the modeling performance criteria

Quality indicators	Welding parameters				Interactions		Error
	ST	WC	EF	WT	WC - WT	EF - WT	
$I_{dep}$	5.90	73.51	–	2.89	–	4.41	13.29
$N_{dia}$	3.17	75.02	3.18	3.99	–	2.32	12.32
$N_{pen}$	53.08	3.54	8.71	14.59	1.96	–	18.12

Abbildung 1.8 Percent contributions of Wpar in the variation of the quality indicators

Model identification		WP <sub>m</sub>	DR <sub>m</sub>	QO <sub>m</sub>	
Modeling variables	ST	1	2	2	
	WC	1	2	1	
	EF	1	2	2	
	WT	1	2	2	
	DR	2	1	1	
Decision criteria	Training RMSE values	I <sub>dep</sub>	0.0080	0.0268	0.0052
		N <sub>dia</sub>	0.1061	0.3767	0.1091
		N <sub>pen</sub>	1.2445	4.9358	0.9146
		RMSE <sub>t</sub>	1.3586	5.3393	1.0288
	Validation RMSE values	I <sub>dep</sub>	0.0245	0.0296	0.0184
		N <sub>dia</sub>	0.3438	0.3408	0.5180
		N <sub>pen</sub>	2.5737	3.7138	1.4585
		RMSE <sub>v</sub>	2.9420	4.0842	1.9949
	RMSE <sub>tot</sub>		4.3005	9.4235	3.9641
	Training MRE values	I <sub>dep</sub>	0.0424	0.1250	0.0322
		N <sub>dia</sub>	0.0176	0.0637	0.0175
		N <sub>pen</sub>	0.0192	0.0705	0.0106
		MRE <sub>t</sub>	0.0793	0.2592	0.0603
	Validation MRE values	I <sub>dep</sub>	0.0784	0.0939	0.0650
		N <sub>dia</sub>	0.0391	0.0515	0.0519
		N <sub>pen</sub>	0.0266	0.0512	0.0180
		MRE <sub>v</sub>	0.1441	0.1966	0.1350
	MRE <sub>tot</sub>		0.2233	0.4558	0.1953

Abbildung 1.9 Modeling evaluation results

Ein quasi optimales Modell entwickelt, das **Schweißparameter** und typische Eigenschaften des dynamischen Widerstands kombiniert.




Abbildung 1.10 Model evaluation using measured and estimated quality indicators

## 1.4 Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding[2]

In diesem Artikel wird ein algorithmisches Framework vorgeschlagen, das auf einem neuronalen Netzwerk mit linear vector quantization (LVQ) basiert und die Klassifizierung von Linsequalität basierend auf einer kleinen Anzahl dynamischer Widerstandsmuster für Kalt-, Normal- und Spritzer schätzt, die während des Stabilisierungsprozesses gesammelt werden.

Die Klassifizierung der Linse-Qualität mithilfe eines LVQ-Netzwerks wurde auf zwei Arten von Controllern getestet: MFDC mit konst. Stromregler and AC mit konst. Wärmeregler.

Um die Dimension des Eingabedatenvektors zu verringern, werden verschiedene Punkt aus dem dynamischen Widerstandsprofil extrahiert und unter Verwendung der Leistung der Testkriterien verglichen.

**Schweißmaschine:** MFDC mit Konstantstromregler, AC mit konstantem Wärmeregler

**Material:** 2,00 mm Feuerverzinkter HSLA-Stahl mit 0,85 mm Galvanisch verzinkter HSLA-Stahl

**Elektrode:** HWPAL25 mit einem Flächendurchmesser von 6,4 mm

**Faktor:**

Tabelle 1.4 Faktor Tab. 4

Faktor	MFDC(Konstantstromregler)	AC(Konstantwärmeregler)
Schweißstrom(kA)	11,5 mit 1 A Anstieg pro Schweißung.	11,3
Elektrodenkraft(lb)	680	680
Schweißzeit	233 ms	16 Zyklen

Elf Batches mit jeweils 300 Schweißnähten (insgesamt 3,300 Schweißnähte ohne Ankerschweißpunkte) wurden mit 10 Elektroden durchgeführt, die nach jeden Batches bearbeitet wurden. Im Fall des MFDC Tests wurde jedes Batche 50 Samples ausgewählt. Deswegen wurde insgesamt 550 Linsedurchmesser gemessen. Davon haben 411 mit guter Qualität, 22 mit schlecht Qualität und 117 mit Spritzer.

Im Fall des AC Tests wurde 720 Samples ausgewählt. Davon 509 mit guter Qualität und 211 mit Spritzer

In allen Tests basiert die Klassifizierung der Linse-Qualität auf dem Widerstandsprofil

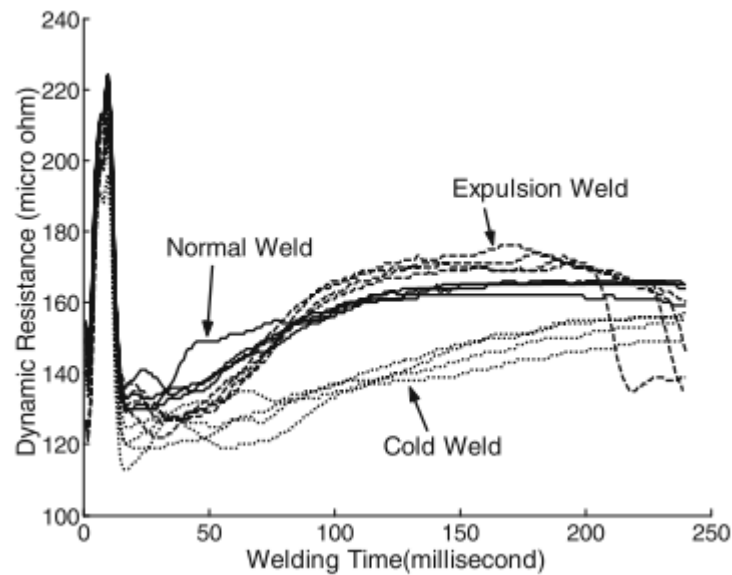


Abbildung 1.11 Sample dynamic resistance profiles for cold, expulsion, and normal welds for a CCC using MFDC




Abbildung 1.12 Sample dynamic resistance profile for cold, expulsion and normal welds for an AC constant heat controller

Das LVQ-Modell wurde an 3, 6 und 5 Samples des sekundären Widerstandsvektors für Kalt-, Normal- bzw. Spritzer-Schweiß trainiert.

LVQ:

- MFDC Konstantstromregler
  - Input:
    - \* 167 Dimension gleich der Anzahl der Millisekunden-Samples in einem Schweißen ohne die ersten 67 ms
  - Hidden Layer:
    - \* 12
  - Output:



- \* schlecht
- \* gut
- \* Spritzer
- AC Konstantwärmeregler
  - Input:
    - \* 24 Dimension gleich der Anzahl der Halbzyklen in einem Schweißen nach der Vorheiz- und Abkühlphase
  - Hidden Layer:
    - \* 12
  - Output:
    - \* schlecht
    - \* gut
    - \* Spritzer

Um die Dimension des Eingangs zu verringern, wurde der tatsächliche Widerstandsvektor durch eine Reihe repräsentativer Merkmale ersetzt.

- $R_{max}$
- $R_{min}$
- $\bar{R}$
- $SD$  des Eingangswiderstands
- $\Delta R$
- $RMS$
- Steigungswert der ersten Region ( $S1$ ) des Eingangswiderstands
- Steigungswert der zweiten Region ( $S2$ ) des Eingangswiderstands
- Steigungswert der dritten Region ( $S3$ ) des Eingangswiderstands
- Steigungswert der vierten Region ( $S4$ ) des Eingangswiderstands
- Binned  $RMS$  des Eingangswiderstands; Der Eingangswiderstand ist in fünf Bins unterteilt und die  $RMS$  werden für jeden Bin berechnet

Die Ergebnisse aus der Anwendung des LVQ neuronalen Netzes trainiert, indem sie die sehr begrenzte Daten während des Stabilisierungsprozesses gesammelt verwenden, sind sehr vielversprechend und werden im Detail berichtet.

Darüber hinaus berichten wir vielversprechende Ergebnisse sehr, wenn ein reduzierter Feature für die Einstufung verwendet wird, anstatt das gesamte dynamische Widerstandsprofil.

## 1.5 Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks[3]

Die Spritzeridentifikation hat für die Bewertung und Kontrolle der Schweißqualität beim RSW größte Bedeutung. Um die Identifikationsgenauigkeit zu verbessern, wurden neuartige neuronale Netze für Wavelet decomposition und Back Propagation (BP) mit der Peak-Peak-Amplitude und dem Kurtosis-Index vorgeschlagen um den Spritzer von Elektrodenkraft-Erfassungssignalen zu identifizieren.

Das Elektrodenkraftsignal ist ein typisches instationäres Signal, dessen verteilte Parameter sich mit der Zeit ändern. Daher konnte weder die Zeitbereichsanalyse noch die Frequenzbereichsanalyse das Signal genau ausdrücken. Die Wavelet-decomposition ist eine Art stabiles und schnelles Zeit-Frequenz-Signalanalyseverfahren.





Figure 5. The flow chart of the algorithm.

Abbildung 1.13 The flow chart of the algorithm

**Signal Processing:** Der Prozess führte eine mehrstufige eindimensionale Wavelet-Analyse unter Verwendung spezifischer Wavelet-Zerlegungsfilter durch, einschließlich des Tiefpassfilters und des Hochpassfilters.



$\downarrow 2$  : Downsampling by the factor of 2

Abbildung 1.14 Flow chart of the coeffs

Schließlich wurde die Energie jedes Detailsignals  $Q_x(t)$  berechnet und das höchste als Zielsignal ausgewählt. Die Peak-Peak-Amplitude und dem Kurtosis-Index des Zielsignals wurden als Eingabeparameter des BP Neur berechnet. Folgende sind 3 typische Kraftsignals, daher könnte die Anschlag-Feature als Hauptspritzermerkmal bei der Unterscheidung des Spritzer verwendet werden.




Abbildung 1.15 The time domain of the electrode force signal

Durch Wavelet decomposition wurde die Signals auf jeden Layer bekommen:

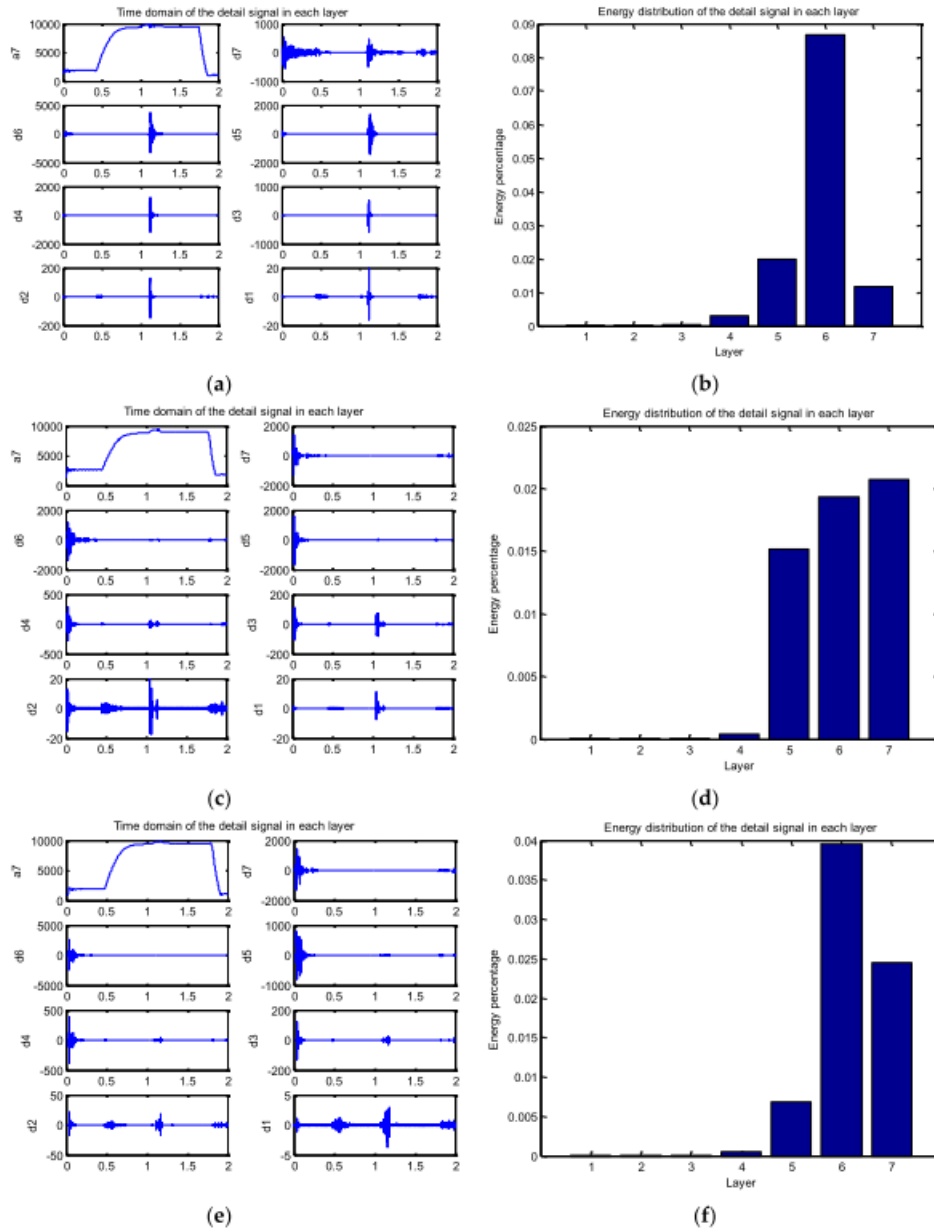


Abbildung 1.16 expulSION signal

In dieser Arbeit wurde der Energieverteilung des Signals in jeder Schicht berechnet und das höchste als Zielsignal ausgewählt.

Data	Peak-to-Peak Amplitude	Kurtosis Index	Layer of the Maximum Energy
1	6962.3	115.78	Layer 6
2	4318.7	83.79	Layer 6
3	4408.2	84.00	Layer 6
4	112.3	8.06	Layer 7
5	408.86	92.93	Layer 7
6	198.21	10.75	Layer 7
7	95.61	7.88	Layer 7
8	1402.1	27.66	Layer 7
9	373.08	8.94	Layer 7
10	2674.9	93.31	Layer 7
11	5047.7	180.80	Layer 6
12	4560.3	141.76	Layer 6
13	4526.8	134.79	Layer 6
14	128.10	15.58	Layer 7
15	841.12	82.14	Layer 7
16	564.10	46.86	Layer 7
17	153.99	14.55	Layer 7
18	228.79	14.58	Layer 7
19	2406.7	83.54	Layer 6
20	5087.6	144.21	Layer 6

Abbildung 1.17 The characteristic indexes of the target signal




Abbildung 1.18 The structure of the BP neural network

- Input:
  - Peak-Peak-Amplitude
  - Kurtosis-Index
- Hidden Layer:
  - 5
- Output:
  - 1 oder -1 (1: Spritzer, -1: ohne Spritzer)

## 1.6 Performances of regression model and artificial neural network in monitoring welding quality based on power signal[8]

In dieser Studie wurde eine Untersuchung durchgeführt, um die Leistung des Regressionsmodells und des künstlichen neuronalen Netzwerks bei der Vorhersage des Linsendurchmessers von RSW durch Überwachung der dynamischen Leistungssignatur zu vergleichen.




Abbildung 1.19 Welding powers signals for various welding qualities

Ein Echtzeit-Erfassungssystem vorgestellt, nach dem der Schweißstrom und die Schweißspannung im Sekundärkreis erhalten wurden. Das Leistungssignal wurde erfasst und analysiert, um die Schweißqualitäten zu charakterisieren. Die Schweißqualitäten können als schlechte, gute Spritzer-Schweißnähte klassifiziert werden. Die Feature mit physikalischen Bedeutungen wurden aus dem Leistungssignal extrahiert, um die Variationen im Signal zu identifizieren, und sie wurden dann als Eingaben des künstlichen neuronalen Netzwerks und des Regressionsmodells benutzt. Die Vorhersagegenauigkeit der Modelle wurde ebenfalls diskutiert.




Abbildung 1.20 Measurement system used in the welding process

**Schweißmaschine:** Hochfrequenz-AC-Schweißgerät

**Material:** 0,4 mm Titanlegierung TC2

**Elektrode:** luftgekühlte Elektrodenelektroden mit flacher Spitze mit Spitzendurchmesser 3

mm.

Faktor:

Tabelle 1.5 Faktor Tab. 5

Faktor	Untergrenze	Obergrenze	Intervall
Schweißstrom(kA)	1,0	2,4	0.2
Elektrodenkraft(N)	76,2	203,2	25,4
Schweißzeit(ms)	4	12	2

**Qualitätsparameter:** Zugscherfestigkeit, Linsendurchmesser. Qualität der Schweißverbindungen ist abhängig von der Linsengrößen, der Zugscherfestigkeit und dem Versagensmodus ist. Die Versagensmodus umfassen Grenzflächenfehler (IF) und Auszugsfehler (PF). Es gibt einen kritischen Linsendurchmesser, der die IF- und PF-Modus verursacht. Daher scheint der Linsendurchmesser der Schlüssel für die Bestimmung der Schweißqualität zu sein.




Abbildung 1.21 Three types of welding joints with different failure: (a) Schlecht mit IF (b) Spritzer mit IF (c) Gut mit PF




Abbildung 1.22 Typical mechanical properties of three types of welding joints

#### Regressionsmodelle:

Feature Auswahl: Stepwise Regression Methode. Die Regressionskoeffizienten wurden unter Verwendung der 170 Samples von Versuchsdaten geschätzt. Die restlichen 80 Samples wurden

zur Validierung dieses Regressionsmodells verwendet.

**ANN:**

- Input:
  - $P_m$  Beta-Spitzenleistungswert
  - $P_n$  Leistungswert am Wendepunkt
  - $\Delta P$  Leistungsschwankung zwischen Wendepunkt und Beta-Spitzenpunkt
  - $P_s, P_s = P_m/\Delta P$  Leistungsabfallrate zwischen Wendepunkt und Beta-Spitzenpunkt
  - $Q, Q = \int P(t) dt$  Numerischer Integrationswert des Leistungssignals während des Schweißvorgangs
- Hidden Layer:
  - 7
- Output:
  - Linsendurchmesser

Die Ergebnisse beweisen, dass ein künstliches neuronales Netzwerk im Vergleich zu dem quadratischen Regressionsmodell, das die schrittweise Regressionsanalyse umfasst, genauere Ergebnisse der Vorhersage des Linsendurchmessers und des Ziels viel besser liefern kann. Darüber hinaus liefert die Methode der quadratischen Polynom-Schritt-Regression möglicherweise keine genauen Werte bestimmter Punkte für einige stark nichtlineare Gleichungen.



## 1.7 Optimization of resistance spot welding process using taguchi method and a neural network[6]

In dieser Studie wurde eine Anwendung vorgestellt, bei der die Taguchi-Methode und ein neuronales Netzwerk kombiniert wurden, um die optimalen Bedingungen für die Verbesserung der RSW-Qualität von hochfestem Stahlblech zu bestimmen.

Schweißmaschine: FANUC a8/4000is

Material: 0,7 mm hoch festes Stahlblech

Faktor:

Tabelle 1.6 Faktor Tab. 6

Faktor	Level 1	Level 2	Level 3	Level 4
Die Durchmesser der Elektrodenspitze(mm)	$\phi 3$	$\phi 4$	$\phi 5$	$\phi 6$
Schweißstrom(A)	6200	7800	9400	11000
Schweißzeit(Zyklen)	8	14	20	26

Rauschfaktor:

Die Proben der Stufe 1 (N1) können ohne Reinigungsbehandlung mit Schmutz und / oder Fett angelaufen sein. Die Oberflächenverunreinigungen wurden entfernt auf Stufe 2 (N2) gereinigt.

Qualitätsparameter: Zugscherfestigkeit

OA-Experiment:  $L16(4^5)$





Abbildung 1.23 SNR graph for the tensile shear strength


ANN:

Insgesamt 64 Simple wurden in einen Trainingsdaten(38), einen Testdaten(13) und einen Validierungsdaten(13) unterteilt.


- Input:
  - Die Durchmesser der Elektrodenspitze(mm)
  - Schweißstrom
  - Elektroden Kraft
  - Schweißzeit
  - Sauberkeit der Probe
- Hidden Layer:
  - 7
- Output:
  - Zugscherfestigkeit




a) Results of simulating different electrode force



b) Results of simulating different size of the electrode tip



c) Results of simulating different welding current



d) Results of simulating different welding time

Abbildung 1.24 The best welding parameters selected by ANN




Abbildung 1.25 Surface conditions of specimens for validating the proposed approach

## 1.8 Quality evaluation by classification of electrode force patterns in the resistance spot welding process using neural networks[7]

In einem servogesteuerten RSW-System wird ein Qualitätsbewertungsverfahren durch Klassifizierung von Elektrodenkraft unter Verwendung neuronales Netzwerk benutzt.

Schweißmaschine: servo-controlled RSW

Material: 0,8 mm dünne Stähle

Faktor:

Tabelle 1.7 Faktor Tab. 7

Faktor	Untergrenze	Obergrenze	Intervall
Schweißstrom(kA)	6	10	1
Elektrodenkraft(N)	1500	2100	200
Schweißzeit(Zyklen)		10	

**Qualitätsparameter:** Zugscherfestigkeit, Elektrodeneindrucktiefe  $e_u$ . Gute Schweißqualität mit starker Schweißfestigkeit und kleiner Elektrodeneindrucktiefe  $e_u$

**Schweißqualitäten nach Elektroden-Kraft-Muster:** Schweißstrom  $I = 8$  kA, Schweißzeit 10 Zyklen. Die Elektrodenkräfte bei 1500 und 1700 N fallen aufgrund des Ausstoßes innerer geschmolzener Materialien durch die große Wärmemenge.




Abbildung 1.26 Electrode force patterns for various welding forces

Schweißstrom steigt von 6 zu 10 kA mit einer bleibenden Elektrode Kraft 2100 N. Im Fall von Schweißströmen von 9 und 10 kA zeigen die Kraftmuster schlechte Formen, da die Kräfte

während des Schweißens plötzlich abfallen, weil das geschmolzene Material durch eine große Wärmemenge aus den hohen Schweißströmen ausgestoßen wird.




Abbildung 1.27 Electrode force patterns for various welding currents

#### ANN:


Die Experiment mit der Schweißströme von 6 bis 10 kA mit einer festen Schweißzeit von 10 Zyklen und einer Schweißkraft von 2100 N.

Durch die Versuchsreihe unter den Schweißbedingungen werden 78 Sätze von Elektrodenkraftmustern für 0,8 mm Stahl gesammelt.

Class of quality*	Number of samples	Indentation (mm)		Shear strength (N)	
		Average	Standard deviation	Average	Standard deviation
1 (I)	16	0.063	0.0076	3551	74.6
2 (P)	14	0.094	0.0067	3885	43.2
3 (G)	16	0.124	0.0046	4199	63.8
4 (R)	16	0.138	0.0065	4297	57.9
5 (E)	16	0.140	0.0041	4503	20.6

\*I is the insufficient welding state, P is the poor welding state, G is the good welding state, R is the rich welding state and E is the excess welding state.

Abbildung 1.28 Welding qualities of the standard welding quality classes



a) Five types of standard electrode force pattern

b) The standard force slope patterns

Abbildung 1.29 Select slope feature from force pattern and used in ANN input

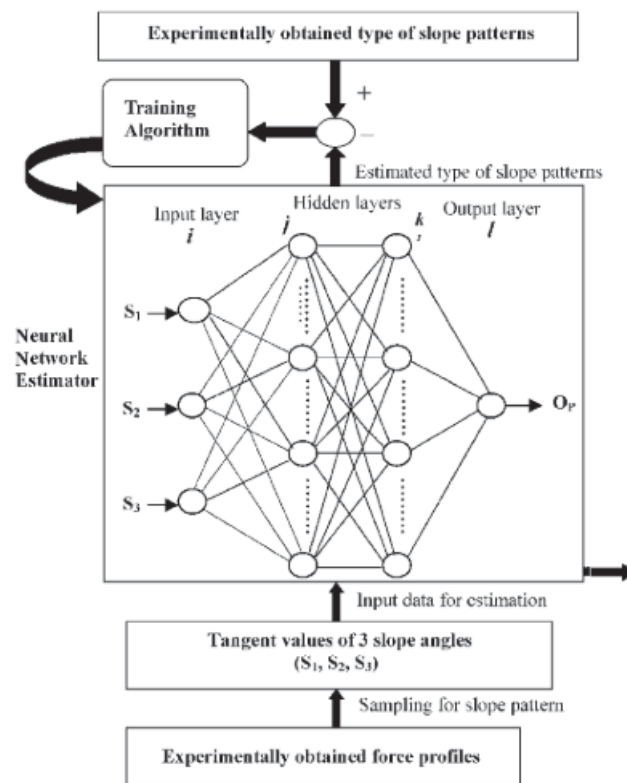


Abbildung 1.30 Block diagram of the training and estimation procedures for electrode force slope patterns using the proposed BP neural network

# Literatur

- [1] Thongchai Arunchai u. a. „Resistance Spot Welding Optimization Based on Artificial Neural Network“. In: *International Journal of Manufacturing Engineering* 2014 (2014), S. 1–6. ISSN: 2356-7023. DOI: [10.1155/2014/154784](https://doi.org/10.1155/2014/154784).
- [2] Mahmoud El-Banna, Dimitar Filev und Ratna Babu Chinnam. „Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding“. In: *The International Journal of Advanced Manufacturing Technology* 36.3-4 (2008), S. 237–248. ISSN: 0268-3768. DOI: [10.1007/s00170-006-0835-5](https://doi.org/10.1007/s00170-006-0835-5).
- [3] Shujun Chen u. a. „Expulsion Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks“. In: *Applied Sciences* 9.19 (2019), S. 4028. DOI: [10.3390/app9194028](https://doi.org/10.3390/app9194028).
- [4] A. El Ouafi, R. Bélanger und J. F. Méthot. „Artificial neural network-based resistance spot welding quality assessment system“. In: *Revue de Métallurgie* 108.6 (2011), S. 343–355. ISSN: 0035-1563. DOI: [10.1051/meta1/2011066](https://doi.org/10.1051/meta1/2011066).
- [5] Wei Li, S. Jack Hu und Jun Ni. „On-line Quality Estimation in Resistance Spot Welding“. In: *Journal of Manufacturing Science and Engineering* 122.3 (2000), S. 511–512. ISSN: 1087-1357. DOI: [10.1115/1.1286814](https://doi.org/10.1115/1.1286814).
- [6] H.-L. Lin. *Optimization of resistance spot welding process using taguchi method and a neural network*.
- [7] Y. J. Park und H. Cho. „Quality evaluation by classification of electrode force patterns in the resistance spot welding process using neural networks“. In: *Proceedings of the Institution of Mechanical Engineers, Part B: Journal of Engineering Manufacture* 218.11 (2004), S. 1513–1524. ISSN: 0954-4054. DOI: [10.1243/0954405042418491](https://doi.org/10.1243/0954405042418491).
- [8] Dawei Zhao u. a. „Performances of regression model and artificial neural network in monitoring welding quality based on power signal“. In: *Journal of Materials Research and Technology* 9.2 (2020), S. 1231–1240. ISSN: 22387854. DOI: [10.1016/j.jmrt.2019.11.050](https://doi.org/10.1016/j.jmrt.2019.11.050).